



深蓝学院  
shenlanxueyuan.com


## 第一章作业思路

主讲人 \*\*\*\*\*



# 问题描述

Implement the line-search steepest gradient descent with Armijo condition.



$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_N) = \sum_{i=1}^{N/2} \left[ 100(x_{2i-1}^2 - x_{2i})^2 + (x_{2i-1} - 1)^2 \right]$$

Your program should properly minimize this Rosenbrock function.


在优化问题中，我们常用的架构无非是：

- 搜索下降方向 → Choose search direction:  $d = -\nabla f(x^k)$
- 搜索确定下降步长 → Backtracking/Armijo line search
- 迭代确定新位置 →  $x^{k+1} = x^k + \tau d$

# Armijo condition

最速下降法Steepest Gradient Descend采用Armijo Condition作为判断

Backtracking/Armijo line search



Choose search direction:  $d = -\nabla f(x^k)$

While  $f(x^k + \tau d) > f(x^k) + c \cdot \tau d^T \nabla f(x^k)$


$\tau \leftarrow \tau/2$

Update iterate  $x^{k+1} = x^k + \tau d$

Repeat this until **gradient is small**  
or **subdifferential contains zero**.

# 结果

optimization of Rosenbrock function



二维Rosenbrock function优化结果

# 补充：可行牛顿法

## 可行牛顿法 Practical Newton's Method

首先初始化  $x, x \leftarrow x_0 \in \mathbb{R}^n$

当  $\|\nabla f(x)\| > \delta$  时, 进行如下计算

do:

$d \leftarrow -M^{-1}\nabla f(x)$

$t \leftarrow \text{backtracking line search}$

$x \leftarrow x + td$

end while

return

其中,  $M$  是一个接近 Hessian 阵的正定矩阵, 以此来替代线性搜索中的求梯度和求 Hessian 阵。

如果函数为凸函数, 则有

避免 hessian 的逆不存在

$$M = \nabla^2 f(x) + \epsilon I, \epsilon = \min(1, \|\nabla f(x)\|_\infty) / 10$$

因为  $M$  是正定的, 因此可以使用 Cholesky factorization

$$Md = -\nabla f(x), M = LL^T$$

如果函数是非凸的, 那么我们通过如下计算  $M$

Bunch-Kaufman Factorization:

$$Md = -\nabla f(x), M = LBL^T$$

核心思想: 对函数进行二阶泰勒展开近似, 每一次不按照梯度走, 二是直接走到近似后的函数的最优位置

$$f(x) \approx \hat{f}(x) \triangleq f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k)$$

Minimizing quadratic approximation


$$\nabla \hat{f}(x) = \nabla^2 f(x_k) (x - x_k) + \nabla f(x_k) = 0$$

$$\Rightarrow x = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

$d$  下降方向

# 结果


optimization of Rosenbrock function




二维Rosenbrock function优化结果

# 结果

optimization of Rosenbrock function



optimization of Rosenbrock function



我们可以发现PNM的迭代步长相比于SGD更大，因此每一步效率更高。而SGD严格按照梯度下降。PNM没有按照梯度下降的原因是PNM在迭代点处进行了二阶泰勒展开，这是一把双刃剑，虽然可以直接求出最优的迭代方向，但是又以后因为二阶展开产生了误差



感谢各位聆听 !  
Thanks for Listening

